LAPORAN PRAKTIKUM / SKENARIO 2

Deteksi Tumor Ganas dengan Machine Learning dan MLflow

Breast Cancer Wisconsin (Diagnostic) - Experiment Tracking dari data hingga model registry

Nama	_____
NIM	_____
Mata kuliah	MLOps - Model Experimentation & Tracking
Environment	Ubuntu + Miniforge/Conda; Python 3.11.17

Catatan finalisasi yang penting
Tabel metrik pada laporan ini ditranskripsikan dari contoh hasil pada materi kuliah (slide 71-72). Nilai tersebut adalah **angka acuan**, bukan bukti bahwa training, MLflow Registry, atau REST serving telah berhasil dijalankan pada komputer mahasiswa. Sebelum laporan difinalisasi, cocokkan hasil aktual pada MLflow UI dan tambahkan screenshot lokal.

Tujuan praktikum

Membangun alur eksperimen klasifikasi yang dapat dibandingkan dan ditelusuri: penyiapan data, baseline, pemilihan model, hyperparameter tuning, evaluasi akhir, pencatatan MLflow, registrasi model, dan pemeriksaan reproduksibilitas.

Versi dokumen: 11 Oktober 2026

1. Latar Belakang dan Tujuan

Masalah yang dipelajari adalah membantu memprioritaskan pemeriksaan lanjutan untuk sampel tumor yang kemungkinan ganas (malignant). Fokus MLOps bukan hanya memperoleh skor model, tetapi mencatat konteks eksperimen agar konfigurasi, data, metrik, dan model dapat ditelusuri kembali.

Dataset dan definisi target

Materi menggunakan *sklearn.datasets.load_breast_cancer*, yaitu dataset diagnostik dengan 569 sampel dan 30 fitur numerik. Label diubah agar kelas positif konsisten: **0 = benign (jinak)** dan **1 = malignant (ganas)**. Dataset ini merupakan benchmark pendidikan; bukan data klinis yang cukup untuk menyimpulkan kelayakan sistem diagnosis.

Kriteria evaluasi yang ditetapkan sebelum eksperimen

Komponen	Keputusan	Alasan
Metrik utama	**Recall kelas malignant**	False negative - sampel ganas terlewat - dianggap memiliki biaya tinggi pada skenario.
Metrik pembatas	**Precision >= 0,90**	Membatasi alarm positif palsu agar kandidat memenuhi batas yang ditetapkan tugas.
Split	80% train / 20% test	Train untuk seleksi dengan 5-fold Stratified CV; test hanya digunakan pada evaluasi kandidat akhir.
Seed	42	Menetapkan pembagian data/fold agar dapat diulang dengan versi data dan library yang sama.

Hipotesis

- **H1:** Logistic Regression sederhana akan lebih baik daripada baseline Dummy pada recall malignant.
- **H2:** Standardisasi fitur dapat meningkatkan recall pada Logistic Regression, KNN dan SVC yang peka terhadap skala fitur.
- **H3:** Tuning hyperparameter SVC dapat meningkatkan recall dengan tetap memenuhi precision CV minimal 0,90.

Prinsip anti-leakage
Preprocessing harus berada di dalam *Pipeline* sehingga scaler hanya di-fit pada data training di setiap fold. Jangan memilih hyperparameter berdasarkan metrik test; test set dipakai satu kali setelah model ditetapkan.

2. Penyiapan Data (L1)

Kode `src/data.py` memuat dataset bawaan scikit-learn, membalik label, membuat train/test split stratified, menghitung fingerprint MD5 dari representasi DataFrame, dan menyimpan CSV serta metadata. File yang dibuat adalah `data/train.csv`, `data/test.csv`, dan `data/metadata.json`.

Ringkasan ukuran data

Bagian	Total	Benign (0)	Malignant (1)	Fungsi
Train	455	285	170	Cross-validation dan fitting akhir kandidat
Test	114	72	42	Evaluasi final satu kali
Total	569	357	212	Dataset benchmark keseluruhan

Alur data dan jejak versi

Dataset bawaan 569 sampel	→	**Target baru** 0 jinak / 1 ganas	→	**Stratified split** 455 train / 114 test
Fingerprint MD5 atas hash baris	→	**Metadata JSON** seed, ukuran, mapping	→	**MLflow run tags** data_md5, split_seed

Fingerprint contoh dari persiapan data yang telah dijalankan pada terminal:

```
ee5481ad12c0896439e993aacc9e8d50
```

Interpretasi hash
Hash digunakan sebagai fingerprint untuk membantu mengenali versi data di dalam eksperimen. Ini bukan mekanisme keamanan kriptografis dan tidak membuktikan bahwa model valid secara klinis.

Perintah untuk meregenerasi split

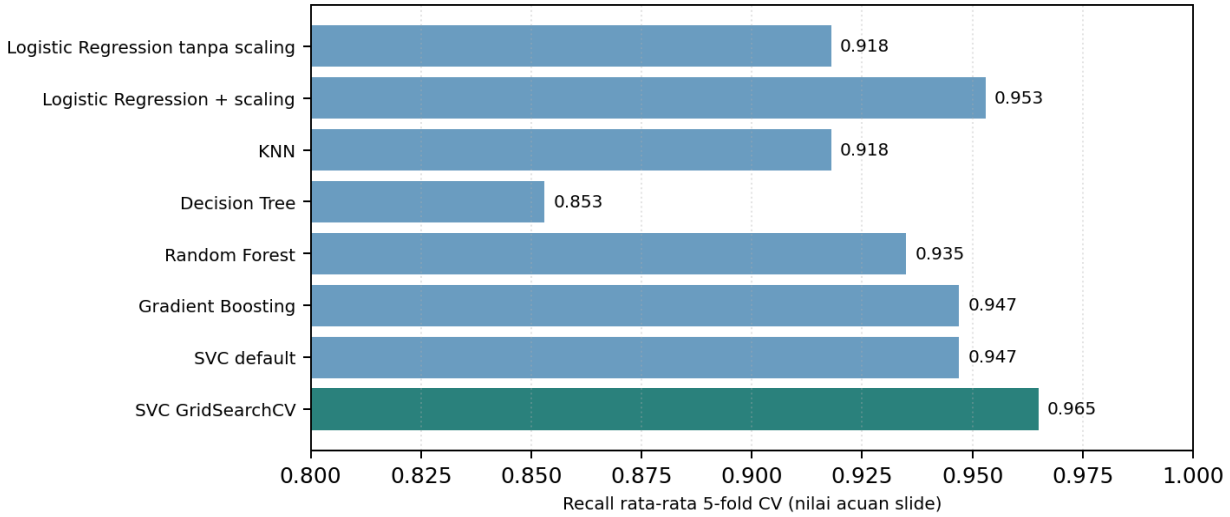
```
python -m src.data
cat data/metadata.json
ls -lh data/
```

3. Eksperimen dan Hasil Pembanding (L2-L5)

Protokol seleksi menggunakan *StratifiedKFold* dengan 5 fold, shuffle aktif, seed 42, dan metrik recall, precision, F1, serta ROC-AUC. Baseline mencakup DummyClassifier dan Logistic Regression tanpa/dengan scaling. Tahap berikutnya membandingkan KNN, Decision Tree, Random Forest, Gradient Boosting, dan SVC; lalu SVC dituning dengan GridSearchCV sebanyak 12 kombinasi C dan gamma.

Asal angka pada bagian ini
Seluruh metrik tabel/grafik di halaman ini bersumber dari tabel contoh hasil pada materi kuliah, slide 71-72. Gunakan output aktual dari MLflow UI untuk mengonfirmasi atau mengganti angka sebelum mengumpulkan laporan.

Recall rata-rata 5-fold CV



Perbandingan metrik dari materi kuliah

Model / run	Recall CV	Precision CV	F1 CV	Precision >= 0,90?
Dummy (most frequent)	0.000	0.000	0.000	Tidak
Logistic Regression tanpa scaling	0.918	0.958	0.937	Ya
Logistic Regression + scaling	0.953	0.977	0.964	Ya
KNN	0.918	0.988	0.951	Ya
Decision Tree	0.853	0.894	0.872	Tidak
Random Forest	0.935	0.964	0.949	Ya
Gradient Boosting	0.947	0.965	0.955	Ya
SVC default	0.947	0.977	0.961	Ya
SVC GridSearchCV	0.965	0.971	0.967	Ya

Pembacaan awal: baseline Dummy mempunyai recall 0, karena tidak mendeteksi kelas positif malignant. Scaling pada Logistic Regression berkaitan dengan peningkatan recall dari 0,918 ke 0,953. SVC GridSearchCV menjadi kandidat dengan recall CV tertinggi di tabel acuan dan precision 0,971, melampaui batas 0,90.

4. Evaluasi Final Test (L6)

Materi kuliah melaporkan contoh evaluasi kandidat SVC pada test set yang ditahan: recall 0,929, precision 1,000 dan ROC-AUC 0,993. Angka ini memberikan contoh bagaimana kriteria recall dan precision dibaca bersama, tetapi bukan bukti hasil dari eksekusi lokal pada environment mahasiswa.

Metrik test dari hasil acuan materi

Metrik	Nilai acuan	Interpretasi
Accuracy	0,974	111 dari 114 sampel diprediksi benar pada test split contoh.
Recall malignant	0,929	39 dari 42 sampel malignant terdeteksi; 3 masih terlewat.
Precision malignant	1,000	Tidak ada prediksi malignant palsu pada test split contoh tersebut.
F1 malignant	0,963	Kombinasi precision dan recall malignant pada threshold prediksi yang digunakan.
ROC-AUC	0,993	Kemampuan ranking skor prediksi pada pasangan kelas dalam test split ini.

Confusion matrix dari hasil acuan

Aktual / Prediksi	Benign (0)	Malignant (1)
Benign (0)	**72** true negative	0 false positive
Malignant (1)	3 false negative	**39** true positive

Kesimpulan medis harus berhati-hati
Recall 0,929 berarti 3 dari 42 sampel malignant masih terlewat pada contoh test tersebut. Precision 1,000 tidak berarti sistem sempurna. Dataset kecil, split tunggal, dan benchmark pendidikan tidak mendukung penggunaan model untuk diagnosis atau keputusan klinis.

5. Experiment Tracking, Registry, dan Serving (L1-L9)

MLflow dipakai untuk menyimpan parameter, metrics, tags, input dataset, model, confusion matrix dan laporan klasifikasi. Semua model kandidat berada di experiment bernama `bc-malignant-detection`. Ini memungkinkan run dibandingkan berdasarkan metrik yang sama, bukan berdasarkan ingatan atau nama file.

Rangkuman pipeline

L1 - Data - Split 80/20, seed 42, data fingerprint dan metadata. Test disimpan untuk evaluasi akhir.

L2 - Baseline - Dummy, Logistic Regression tanpa scaling dan dengan StandardScaler untuk menguji H1-H2.

L3 - Model selection - KNN, Tree, Random Forest, Gradient Boosting dan SVC dengan CV/fold identik.

L4 - Tuning - GridSearchCV 12 kombinasi SVC; satu parent run dan 12 child trials.

L5 - Selection - Filter precision CV >= 0,90; urutkan recall CV menurun dan F1 sebagai tie-breaker.

L6 - Test - Evaluasi kandidat terpilih satu kali; simpan test metrics dan confusion matrix.

L7 - Registry - Daftarkan model; tag challenger dan quality gate untuk alias champion.

L8 - Serving - Load model melalui models:/bc-malignant-classifier@champion dan REST API lokal.

L9 - Reproduce - Lacak run, parameter, fingerprint data dan git commit jika tersedia.

Quality gate yang diterapkan

Kandidat harus memenuhi precision test minimal 0,90. Untuk mengganti champion yang sudah ada, recall test juga harus melampaui recall champion setidaknya 0,005 dan keduanya harus memakai fingerprint test split yang sama. Ini merupakan aturan implementasi praktikum; persetujuan gate tidak sama dengan validasi klinis.

Artefak yang harus tampak di MLflow UI

- Parameters dan tags: model_family, stage, data_md5, split_seed, konfigurasi classifier.
- Metrics: cv_recall_mean/std, cv_precision_mean/std, cv_f1_mean/std, cv_roc_auc_mean/std dan metrik test kandidat final.
- Artifacts: model, search_space.json, confusion matrix out-of-fold/test, classification report dan requirements.txt.
- Model Registry: versi model, alias challenger/champion, status quality gate.

6. Cara Menjalankan Paket Kode di Ubuntu

Gunakan folder proyek yang disediakan dalam ZIP dan environment Miniforge/Conda. Karena environment `bc-mlops` milik mahasiswa sudah berisi Python 3.11.17, pandas 3.0.6, scikit-learn 1.9.1, matplotlib 3.11.2, requests 2.34.2 dan MLflow 3.17.0, environment yang ada dapat digunakan tanpa membuatnya ulang jika impor semua library berhasil.

Terminal 1 - Tracking Server

```
conda activate bc-mlops
export MLFLOW_TRACKING_URI=http://127.0.0.1:5000
mlflow server \
  --backend-store-uri sqlite:///mlflow.db \
  --default-artifact-root ./mlartifacts \
  --host 127.0.0.1 --port 5000
```

Biarkan server hidup dan buka http://127.0.0.1:5000 pada browser.

Terminal 2 - urutan eksperimen

```
conda activate bc-mlops
export MLFLOW_TRACKING_URI=http://127.0.0.1:5000
python -m src.data
python -m src.train
python -m src.analyze
python -m src.evaluate
python -m src.register
python -m src.reproduce
```

Jalankan perintah satu demi satu; jangan teruskan bila salah satu tahap gagal. Evaluasi dijalankan setelah selection, dan registry baru dilakukan setelah test metrics tersedia.

Terminal 3 - serving setelah @champion ada

```
export MLFLOW_TRACKING_URI=http://127.0.0.1:5000
mlflow models serve \
  -m models:/bc-malignant-classifier@champion \
  -p 5001 --env-manager local
```

```
python -m src.predict_api --url http://127.0.0.1:5001/invocations --rows 3
```

Perhatian
Perintah di halaman ini adalah instruksi eksekusi. Keberhasilan MLflow server, training, registry dan serving harus dibuktikan dari output lokal dan screenshot. Tabel acuan dari materi tidak membuktikan tahap-tahap itu telah berhasil.

7. Kesimpulan, Keterbatasan, dan Finalisasi

Skenario memperlihatkan bahwa accuracy saja dapat menyesatkan pada klasifikasi medis. Baseline Dummy dapat memberi accuracy yang tampak layak karena mayoritas contoh benign, tetapi recall malignant sebesar nol pada tabel materi. Karena false negative menjadi perhatian utama, recall dipilih sebagai metrik optimasi, sedangkan precision >= 0,90 digunakan sebagai batas kelayakan kandidat.

Standardisasi fitur pada Logistic Regression dan pencarian hyperparameter SVC menjadi eksperimen yang dapat dibandingkan jika data split, fold CV dan metrik dibuat konsisten. MLflow menambah nilai MLOps dengan mencatat parameter, hasil, artefak, dataset dan lineage, sementara registry/alias menyediakan pola promosi model yang bisa dikontrol.

Bukti yang perlu ditambahkan sebelum laporan final dikumpulkan

[ ] Isi nama dan NIM pada halaman sampul.

[ ] Screenshot MLflow table/compare view dari run lokal.

[ ] Screenshot parent run GridSearch dan 12 child trials.

[ ] Catat metrik aktual dari outputs/test_metrics.json serta confusion matrix.

[ ] Screenshot registry version dan alias champion bila quality gate lolos.

[ ] Screenshot contoh respons REST API bila serving berhasil.

[ ] Push kode ke GitHub dan masukkan URL repository ke laporan bila diminta.

Keterbatasan

Laporan ini menggunakan hasil acuan yang tercetak di materi kuliah untuk menjelaskan metode dan interpretasi. Nilai lokal dapat berbeda karena versi paket, split, atau detail eksekusi. Dataset kecil dan test set tunggal bukan validasi eksternal. Model tidak boleh digunakan untuk diagnosis atau untuk mengganti keputusan profesional medis.

Referensi

1. Ramdani, A. L. *Model Experimentation & Tracking in MLOps*, materi kuliah Sains Data/ITERA, khususnya slide 54-81 (dokumen tugas yang diberikan).

2. Scikit-learn, *load_breast_cancer*: https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_breast_cancer.html.

3. MLflow Documentation, Tracking: https://mlflow.org/docs/latest/ml/tracking/.

4. MLflow Documentation, Model Registry: https://mlflow.org/docs/latest/ml/model-registry/.

5. MLflow Documentation, Model Serving: https://mlflow.org/docs/latest/ml/deployment/.

Akhir laporan - validasi hasil dan bukti eksekusi lokal tetap menjadi tanggung jawab proses praktikum.